

# ニューラル機械翻訳の動向

中澤 敏明

科学技術振興機構

# 自己紹介



- 修士: 東大情報理工
- 博士: 京大情報学
- 現在: 科学技術振興機構(JST) 研究員  
– 日中・中日機械翻訳実用化プロジェクト  
(2013-2017年度)
- NLP若手の会2017年委員長 <http://yans.anlp.jp>
- NLP2018大会プログラム委員

# 目次

- NMTの基礎
  - SMTとNMTとの比較
  - Encoder-decoderモデル
  - Attention-based NMT
  - NMTの特徴と短所
- NMTの課題
  - 扱える語彙数が少ない
  - 訳抜けと重複
  - 何を学習しているのかわからない
- NMTのその他の話題
  - 多言語翻訳
  - Low/Zero-resource翻訳
  - モデルの軽量化
  - 特殊タグの埋め込み
  - RNN以外のNMTモデル
- まとめ

# 目次

- NMTの基礎
  - SMTとNMTとの比較
  - Encoder-decoderモデル
  - Attention-based NMT
  - NMTの特徴と短所
- NMTの課題
  - 扱える語彙数が少ない
  - 訳抜けと重複
  - 何を学習しているのかわからない
- NMTのその他の話題
  - 多言語翻訳
  - Low/Zero-resource翻訳
  - モデルの軽量化
  - 特殊タグの埋め込み
  - RNN以外のNMTモデル
- まとめ

# ニューラル機械翻訳(NMT)の プロダクト化

2014 Sequence to Sequence Learning with Neural Networks

[Sutskever et al., NIPS2014]

2015/05 Baidu 中 $\leftrightarrow$ 英

2016/08 SYSTRAN 12言語 (日、韓、英、仏など)

2016/10 WIPO 中、日、韓 $\rightarrow$ 英 (特許文)

2016/11 Microsoft 10言語

(英、日、中、仏、独、西、葡、露、伊、刺)


2016/11 Google 8言語

(英、日、中、韓、仏、独、西、葡、土)

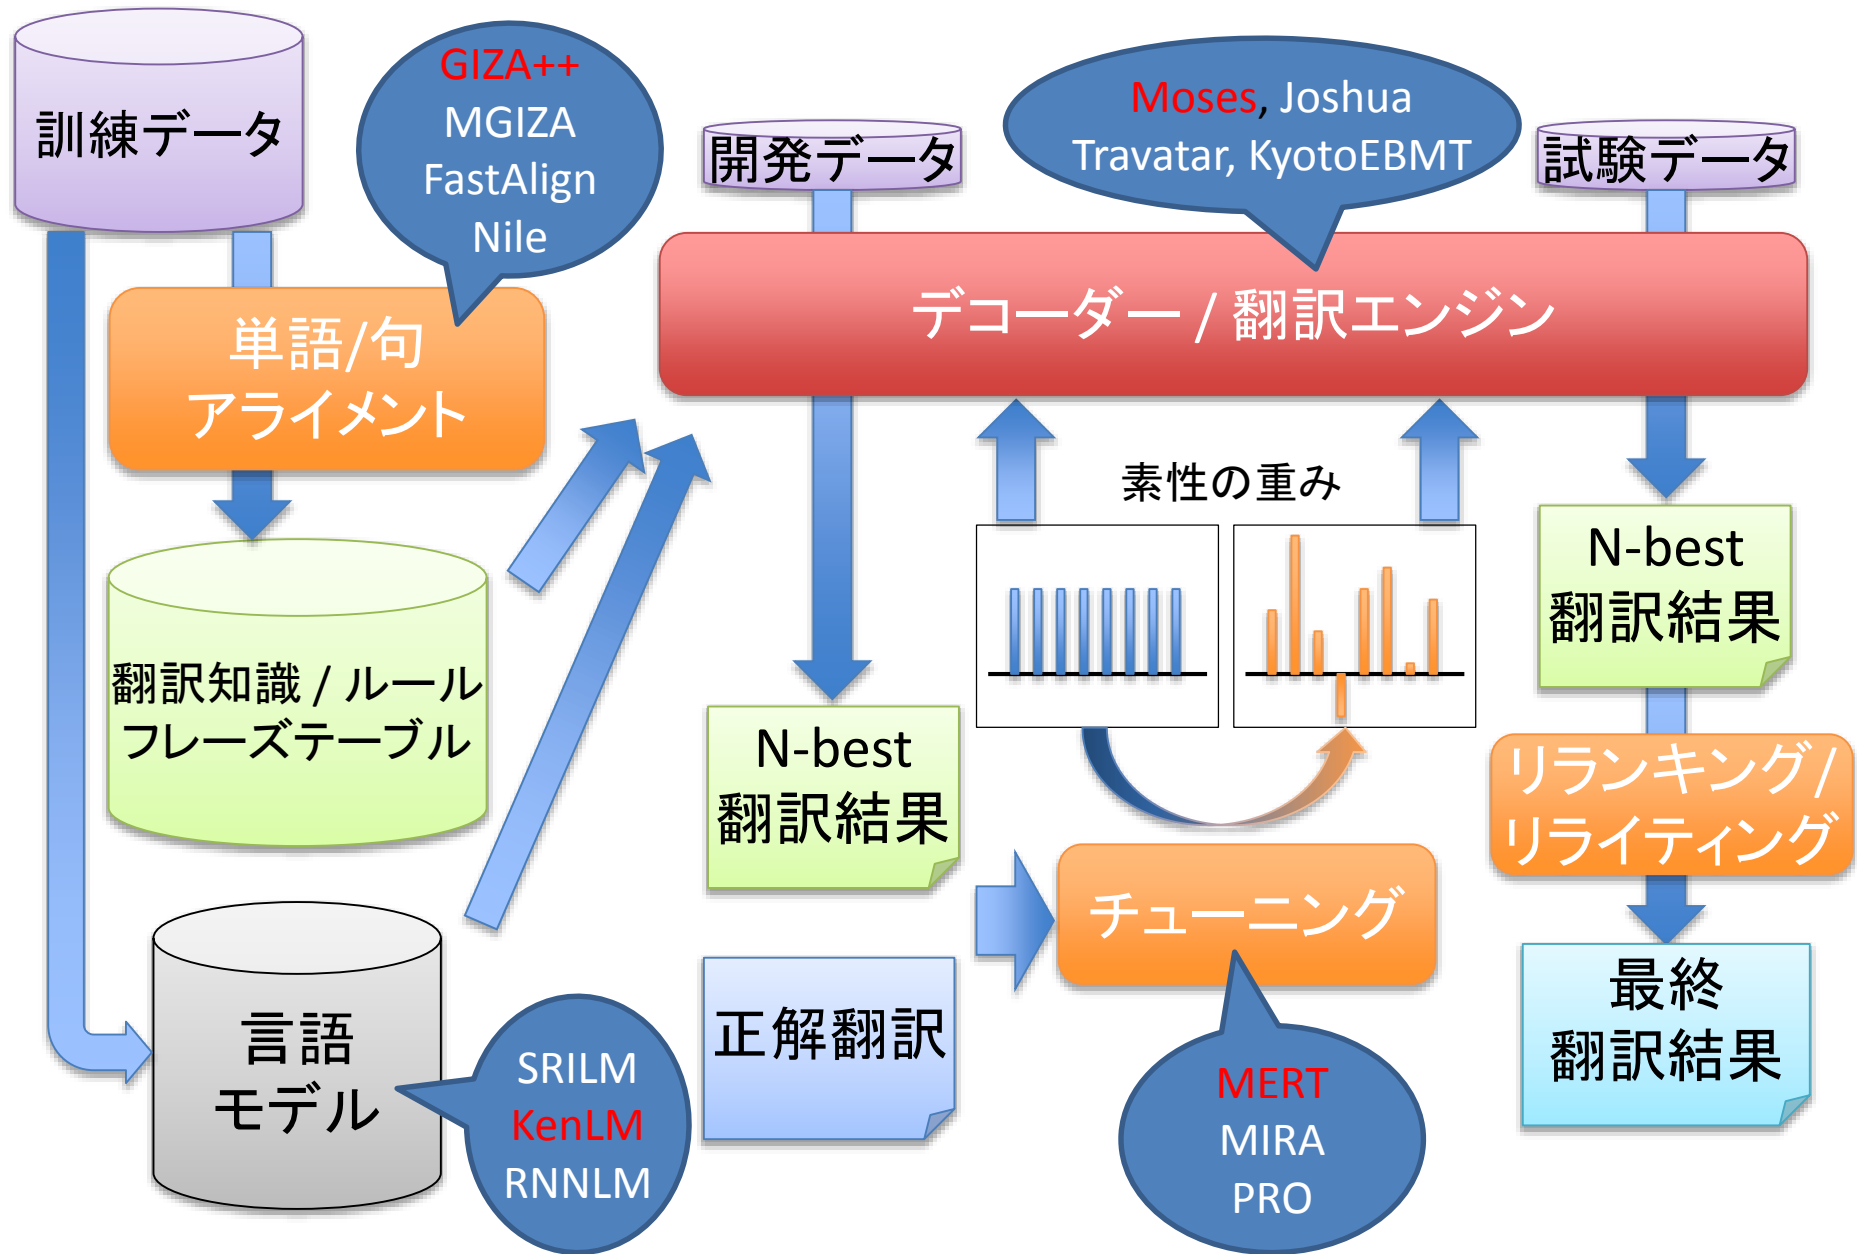
$\rightarrow$  現在は英語と全ての言語との間でNMT

英語以外の言語間は、おそらく英語を介してのブリッジング

# どれぐらい進化したの？

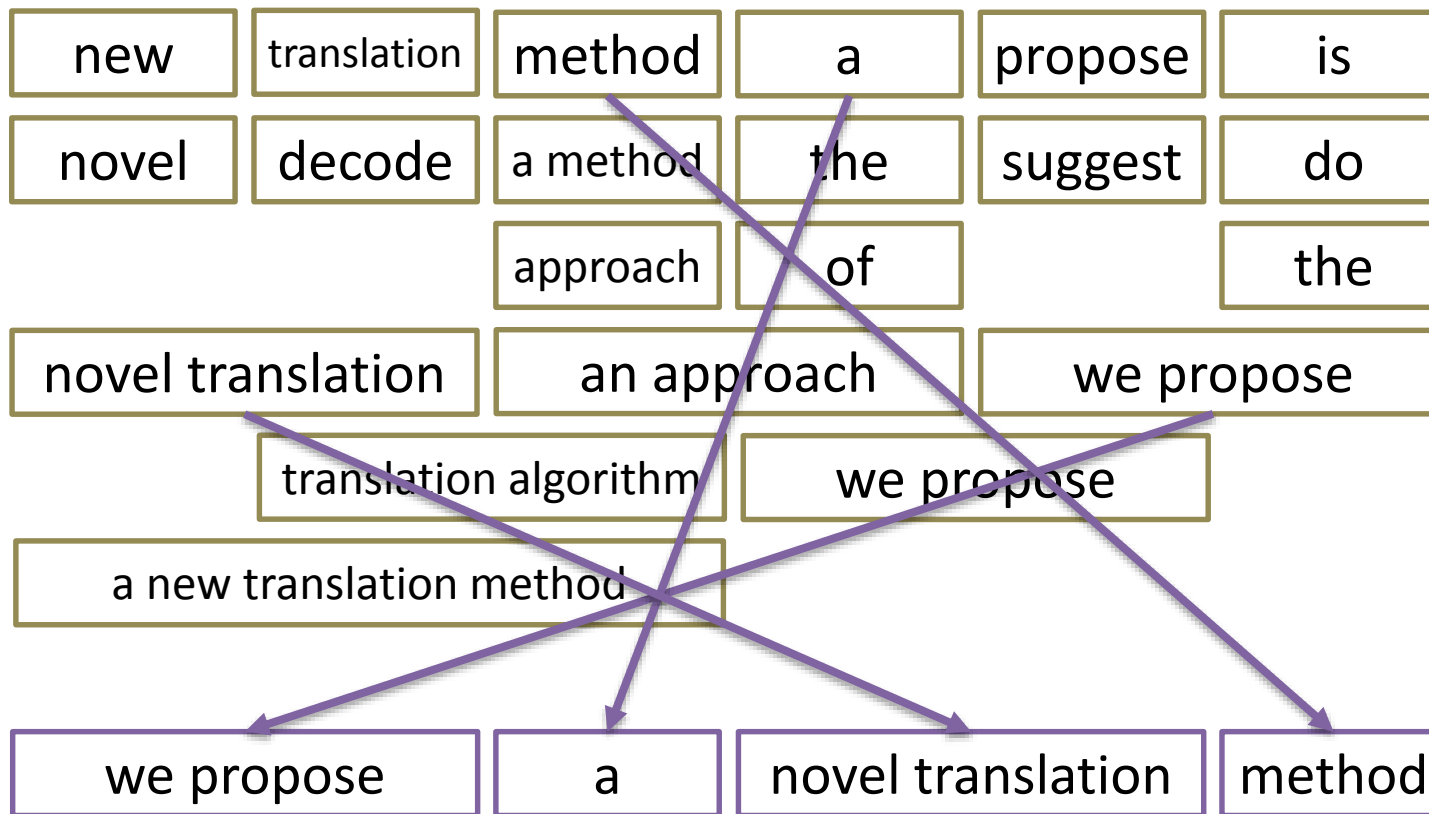


# 一般的な統計翻訳(SMT)の枠組み



# フレーズベースSMTのデコーディング

新たな 翻訳 手法 を 提案 する

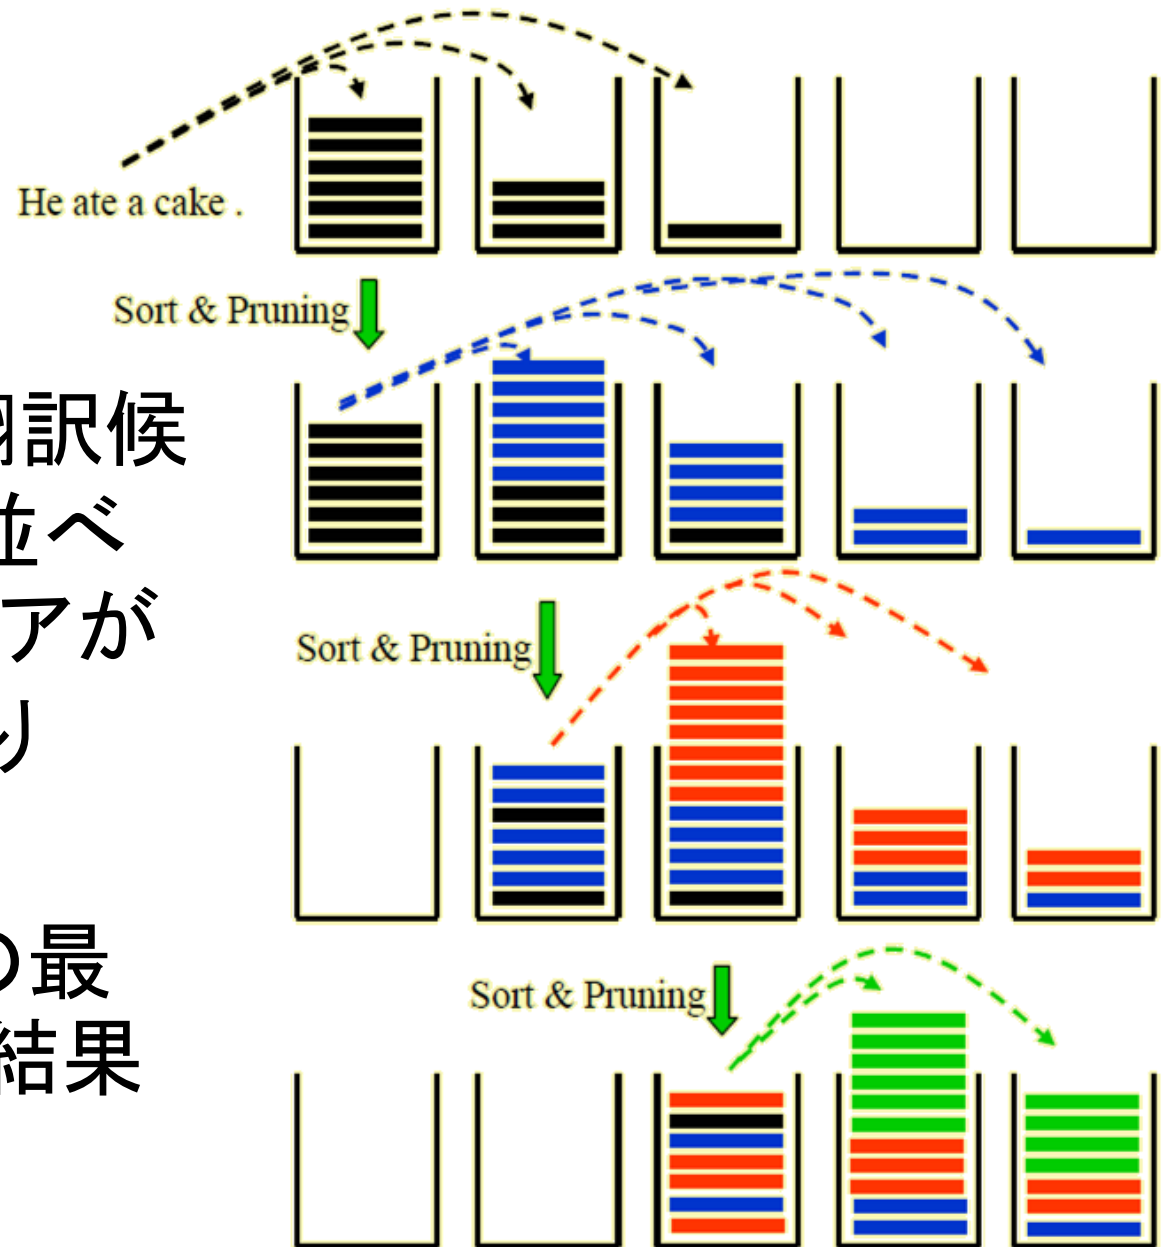


フレーズ  
テーブル



# マルチスタックビームサーチ

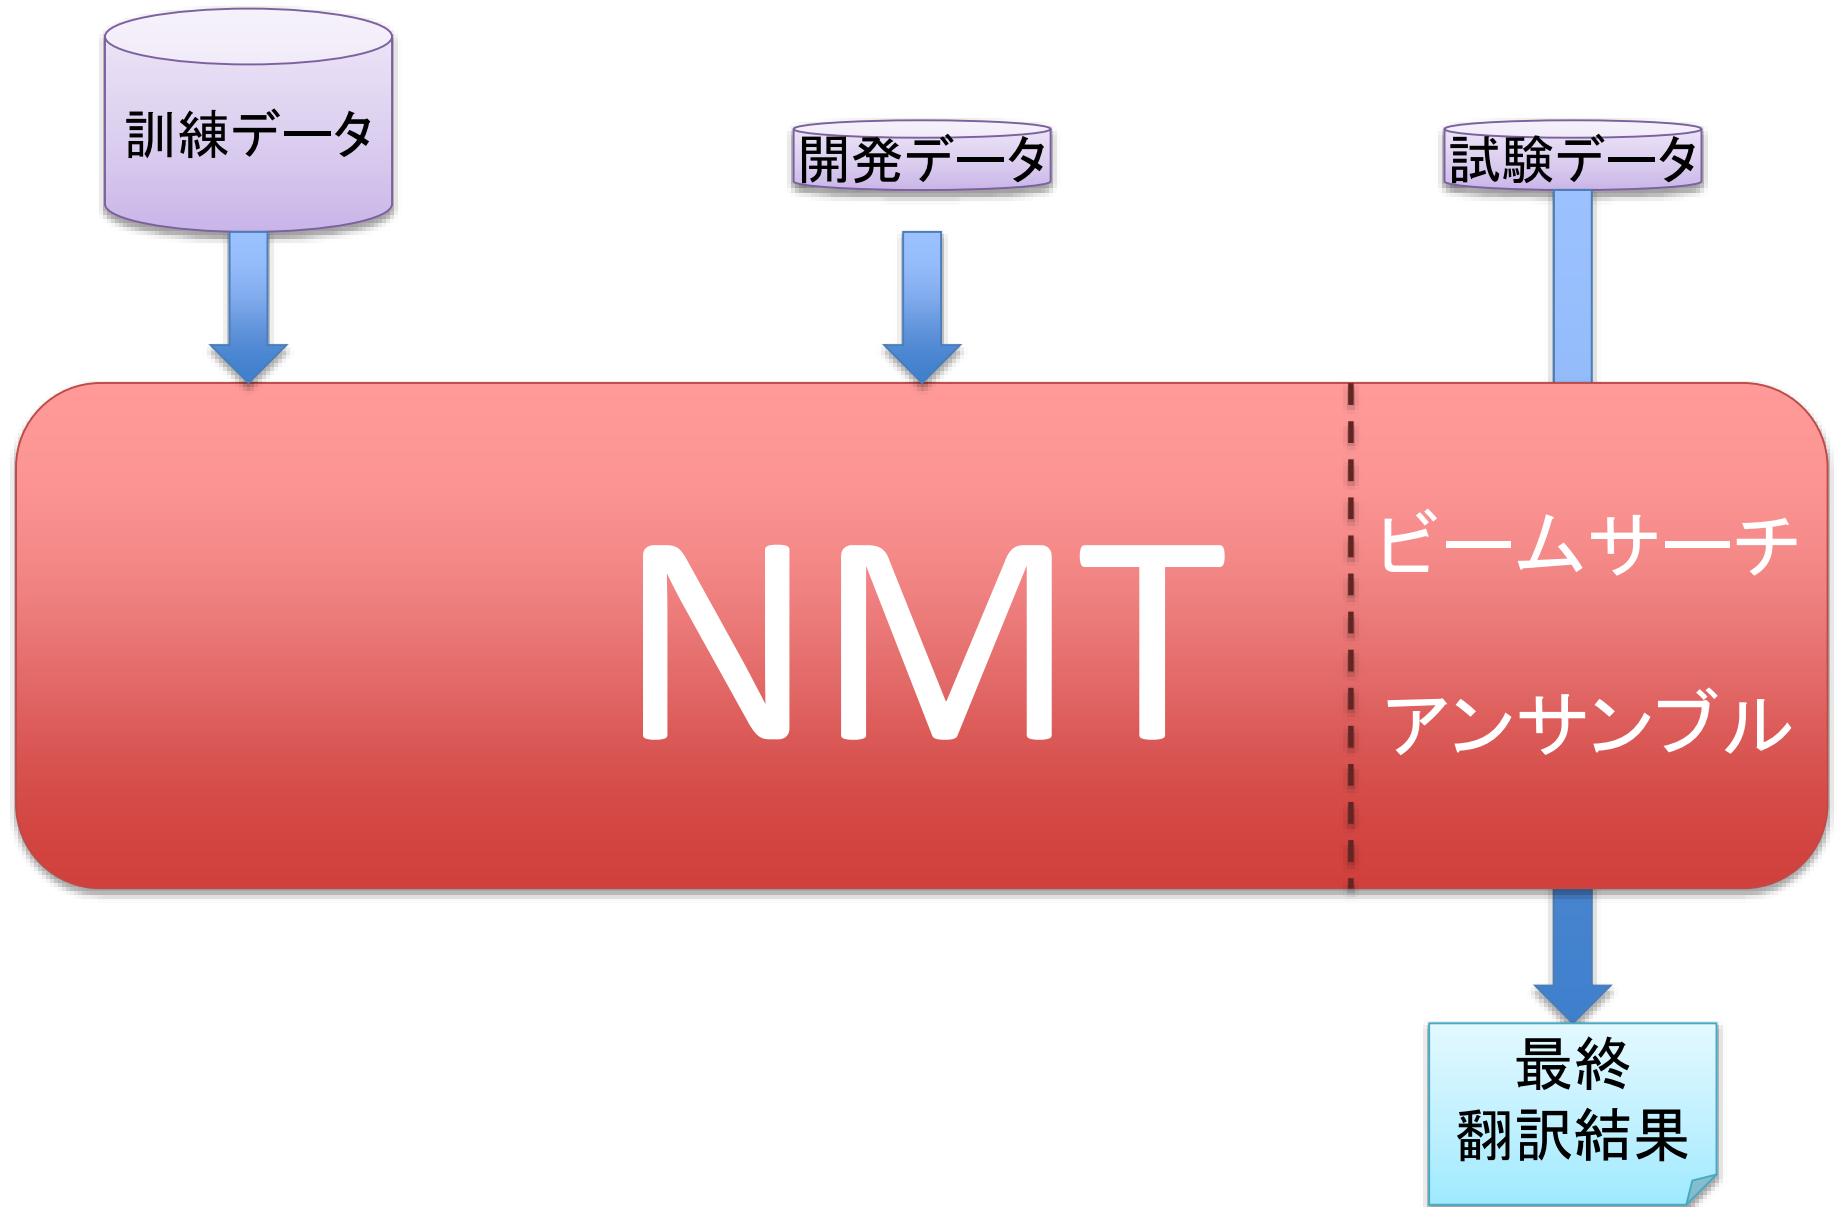
- 翻訳された入力  
単語数ごとに  
スタックを用意
- 各スタック内で翻訳候補  
をスコア順に並べ  
替え (sort)、スコアが  
低いものを枝刈り  
(pruning)
- 最後のスタックの最  
高スコアが翻訳結果



# 一般的な統計翻訳(SMT)の枠組み

- トレーニング、チューニング、テストの大きく3ステップに分かれる
- トレーニングに使うモデルと翻訳(デコーディング)に使うモデルは完全独立なことが多い
  - トレーニング = IBM model、デコーディング = log linear
- チューニングは一般にBLEUに対して行われる
- デコーディングは入力文を小さな部分ごとに目的言語に「置き換える」ことで行い、全ての部分が置き換えられたら翻訳終了

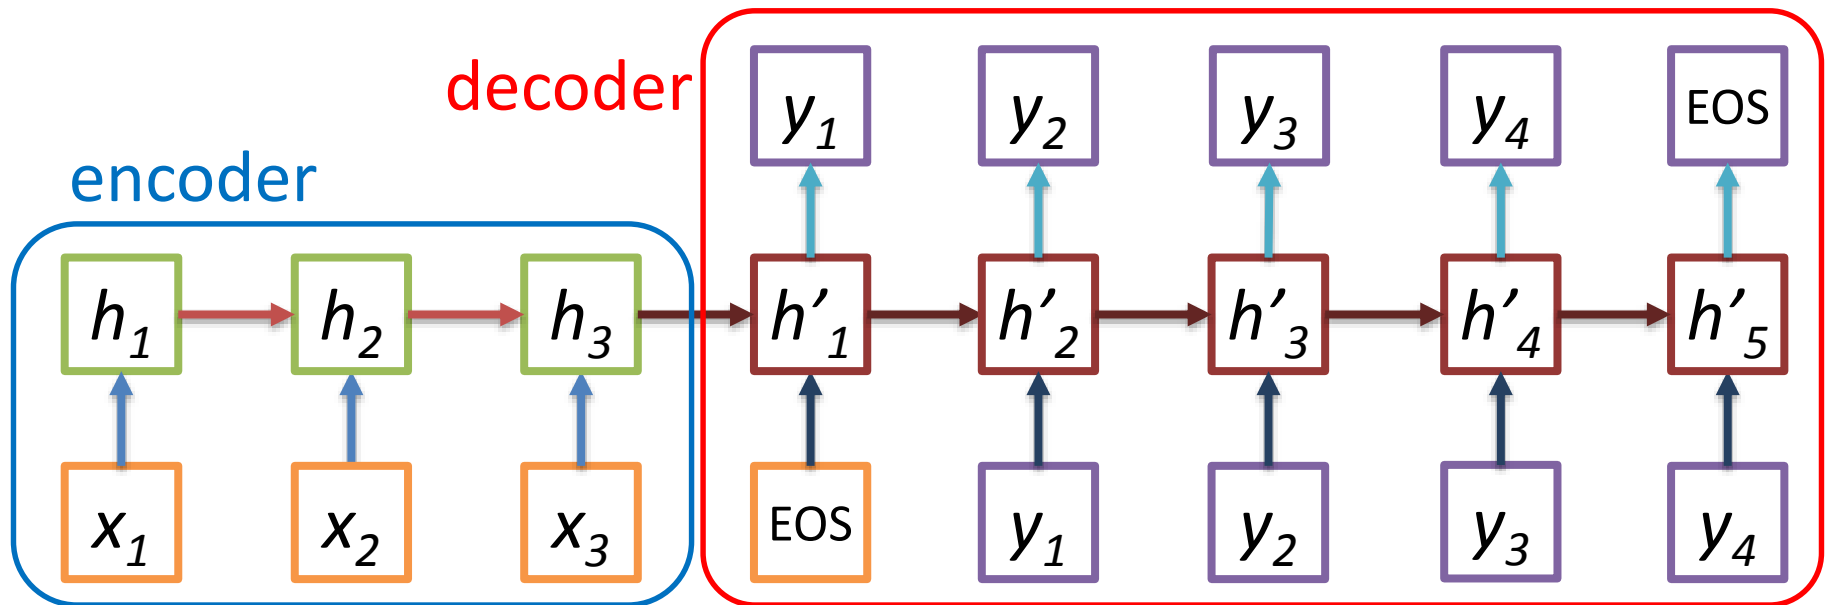
# 一般的なニューラル翻訳(NMT)の枠組み



# Sequence to Sequence Learning

[Sutskever et al., 2014]

- 通常のRNNは入力と出力の長さが同じでなければならないし、順序も一致していなければならない
- 機械翻訳では当然入力と出力の長さが違うし、語順も異なる
- 入力側と出力側で別々のRNNを使おう！



# Sequence to Sequence Learningの欠点

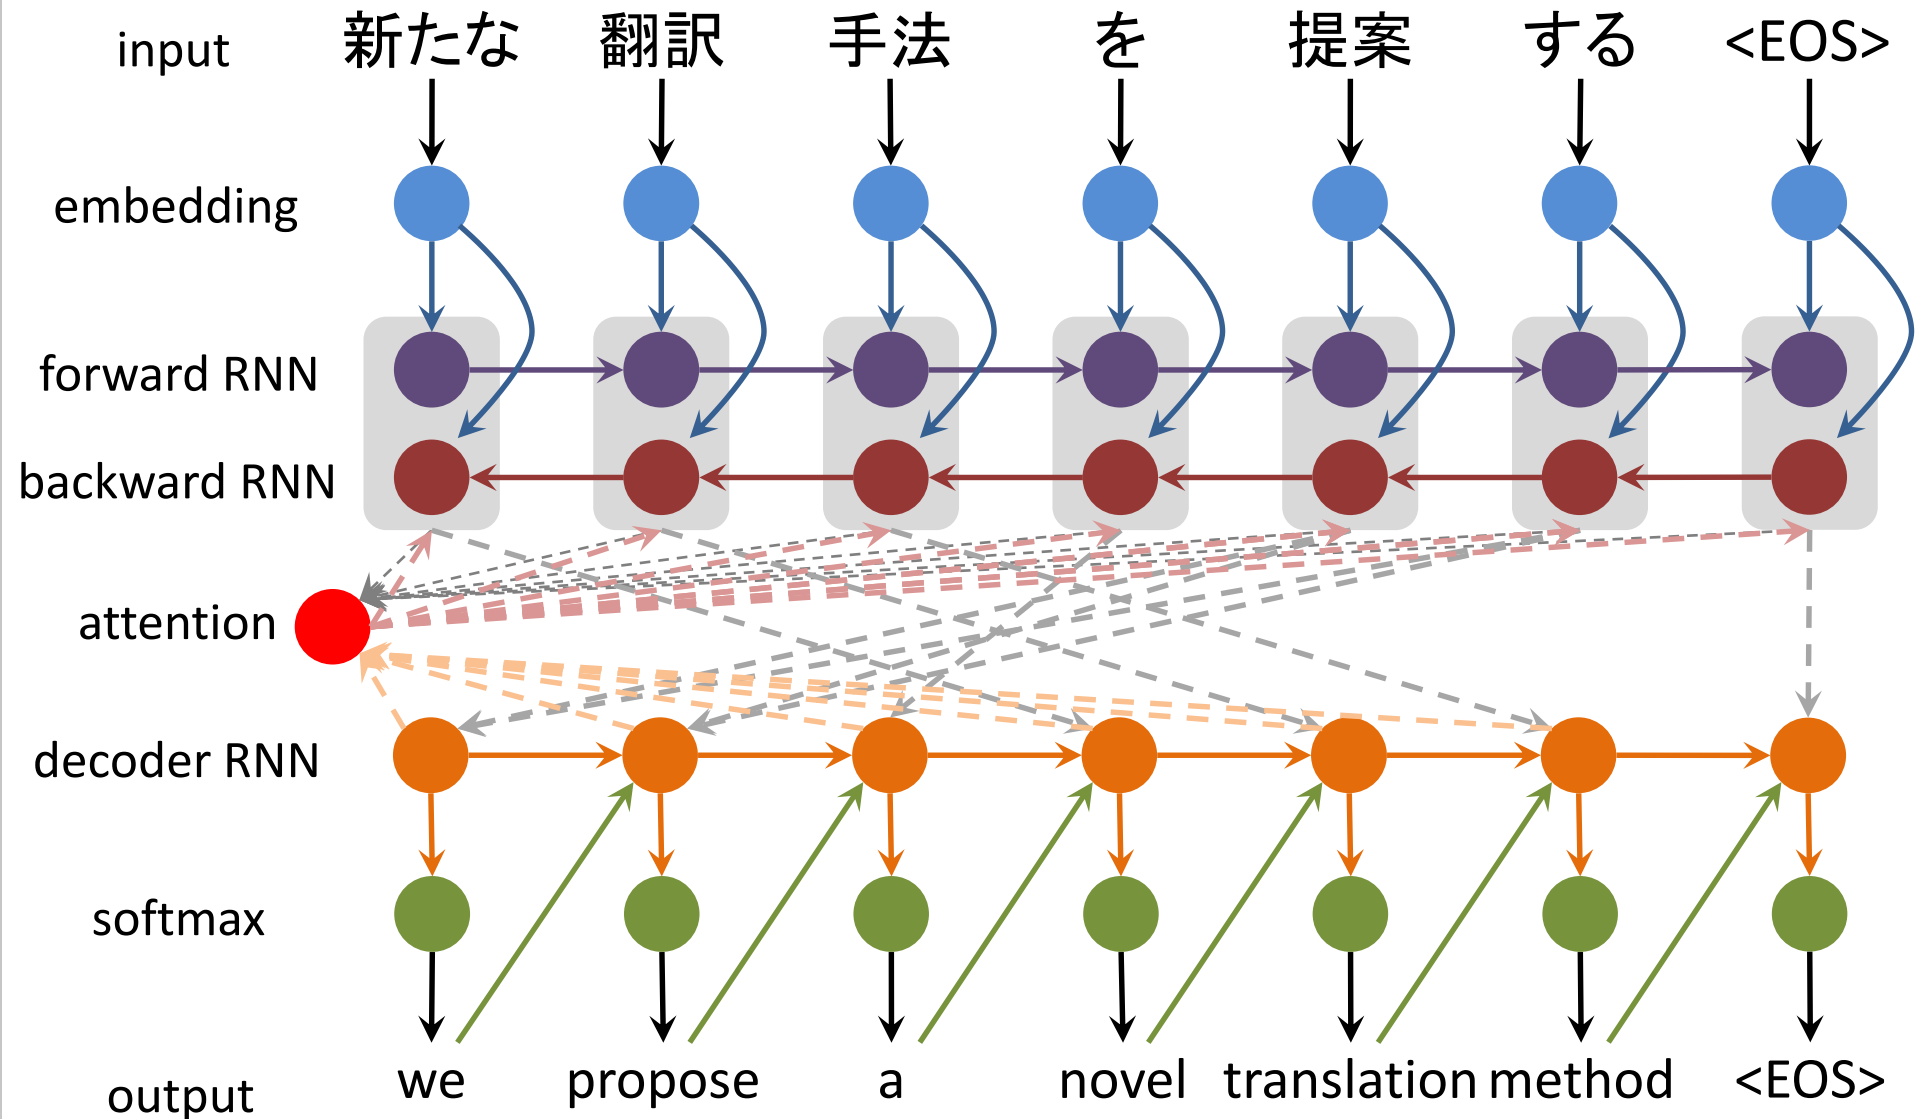
- 入力文の情報を1つの固定長のベクトルに押し込めている
  - 長い文だと翻訳精度が極端に落ちる
  - 入力文を逆順に入れると翻訳精度が上がるという黒魔術が発見される

隠れ層の状態を全て保存しておいて  
翻訳時に適宜参照(=attention)しながら  
翻訳しよう！

ついでにRNNを両方向走らせよう！  
(=bidirectional RNN)

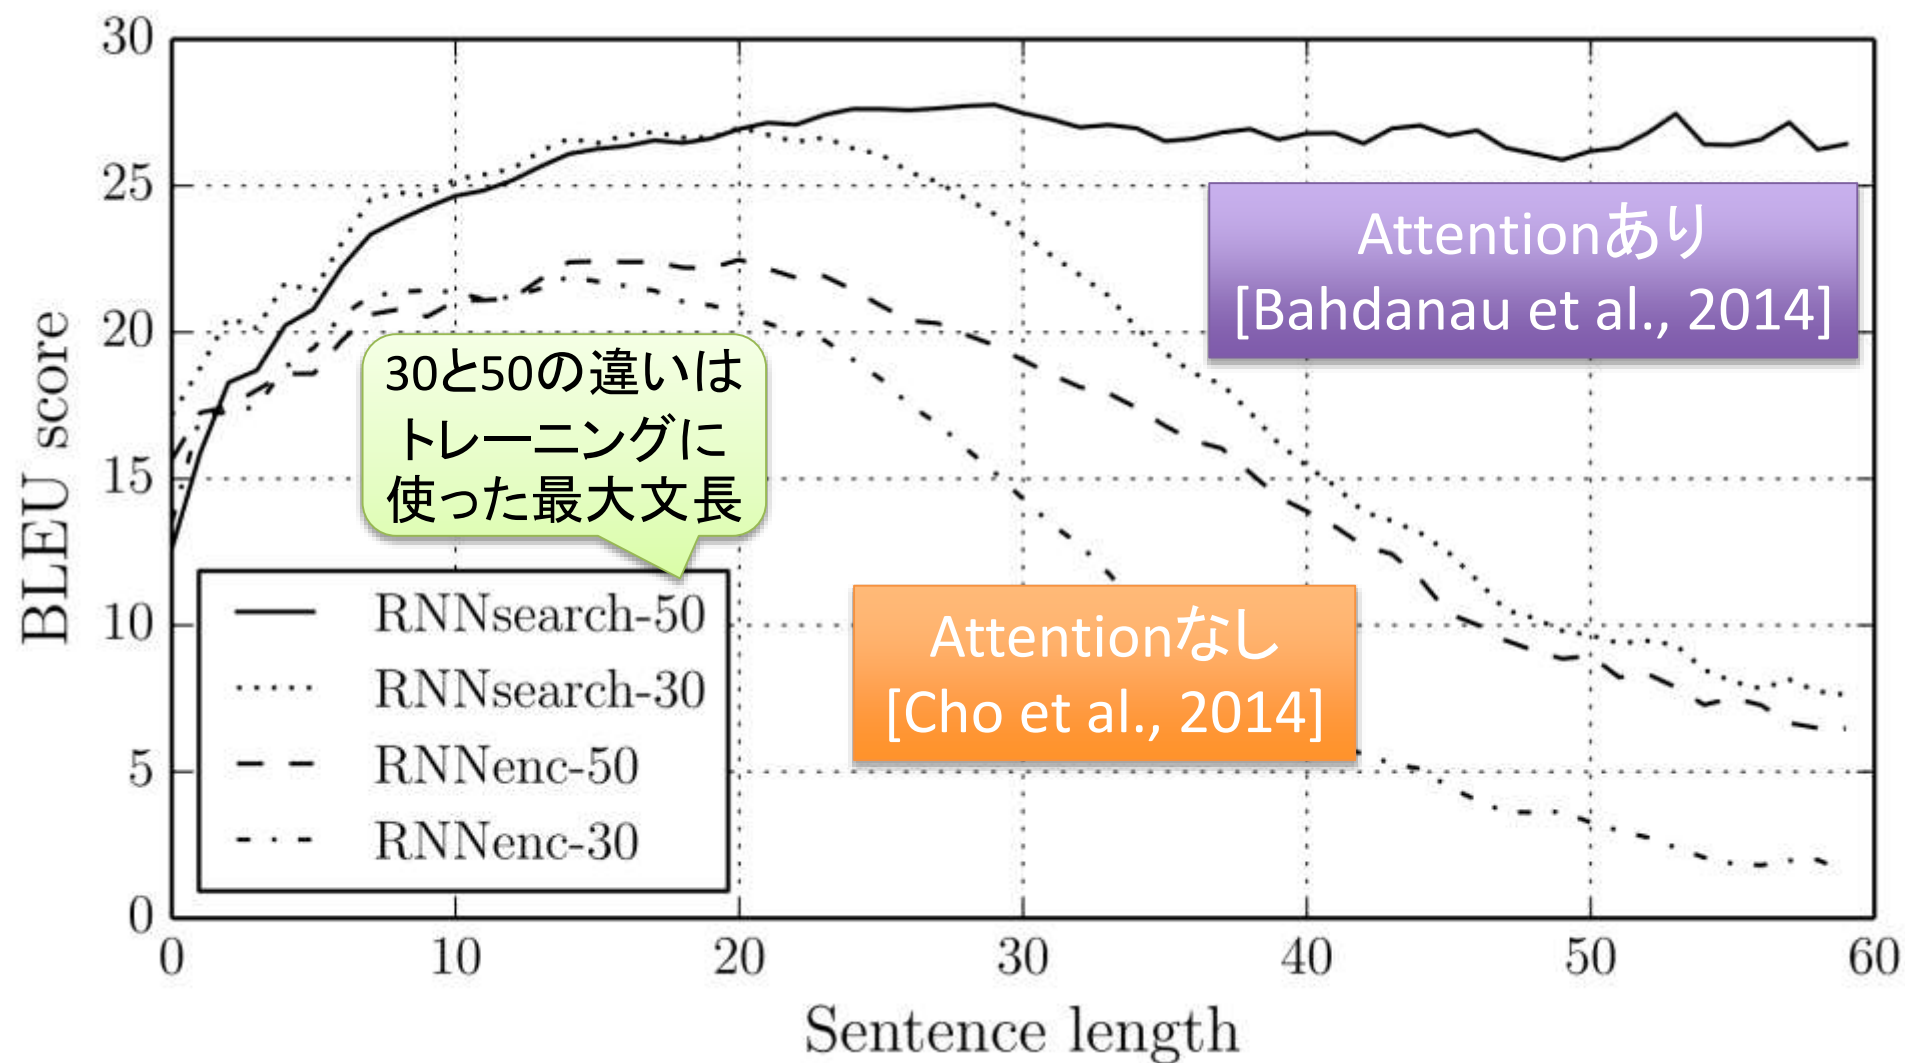
# Attention-based Neural Machine Translation

[Bahdanau et al., 2014]



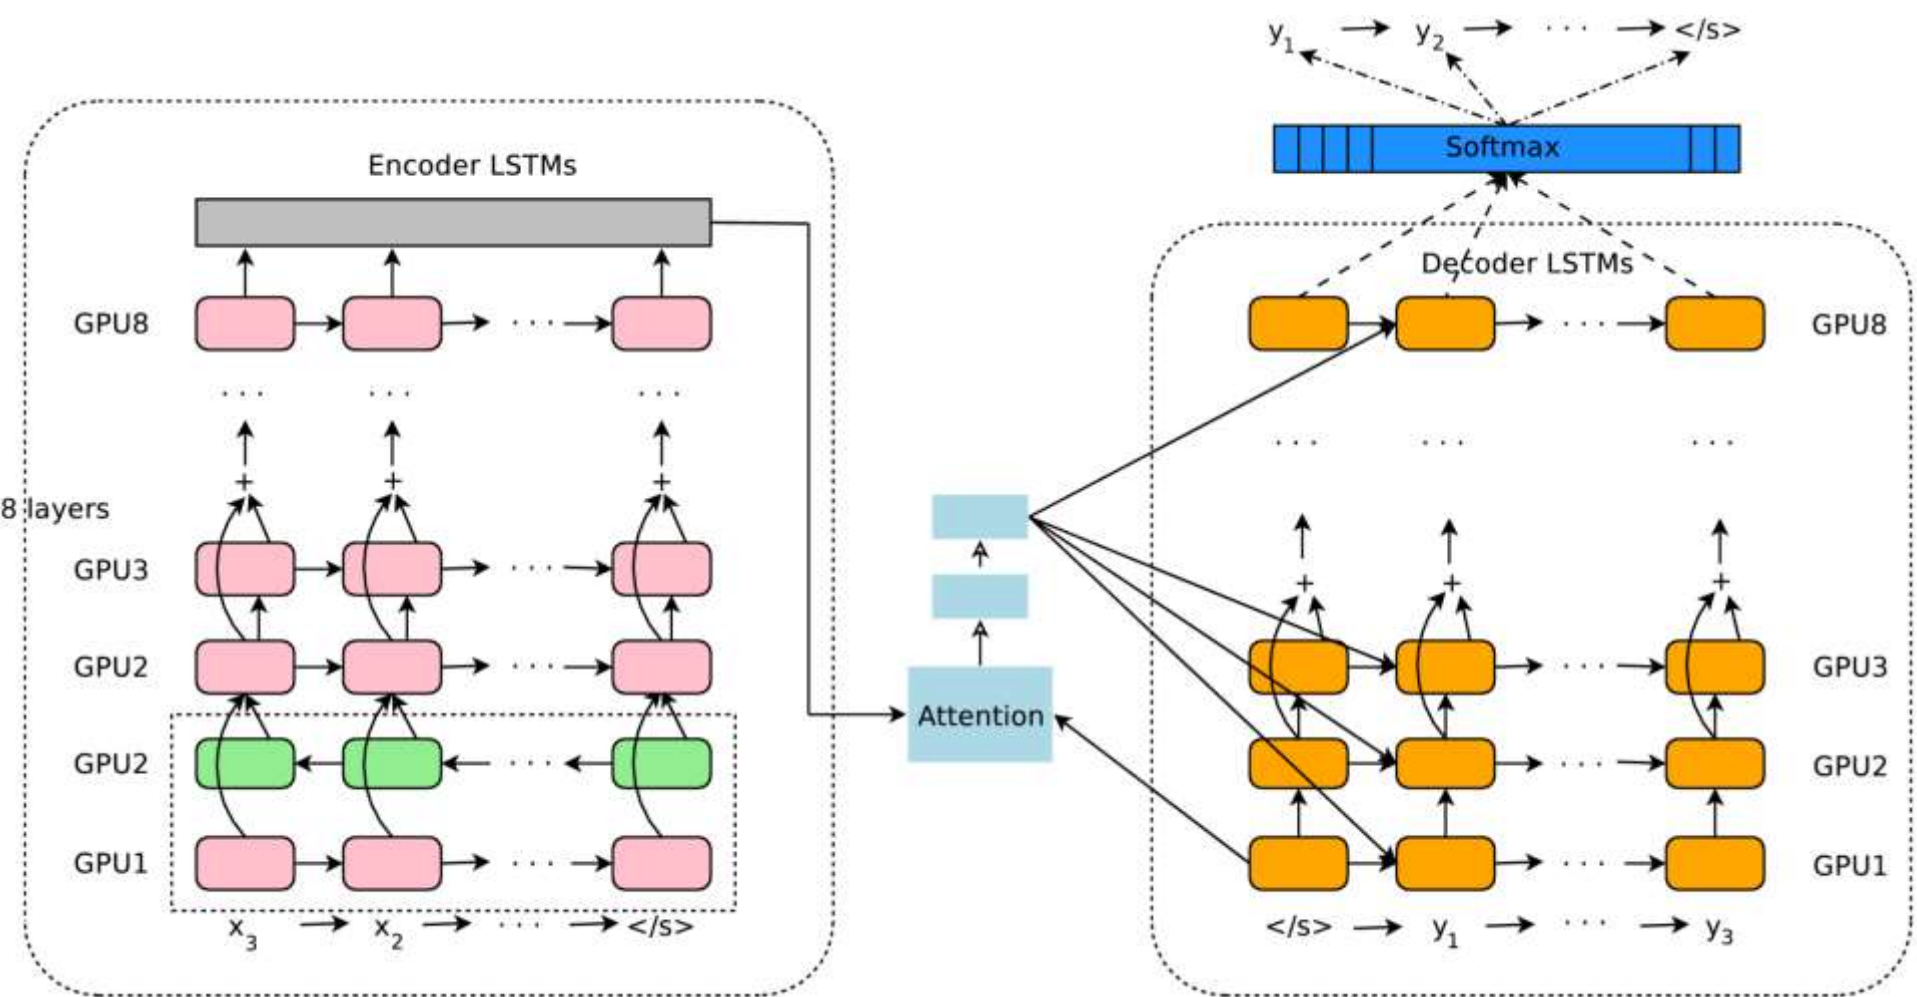
# Attentionの導入による効果

- 長い文でも翻訳精度が落ちにくい！



# Google's Neural Machine Translation (GNMT)

[Wu et al., 2016]





# ビームサーチ

- SMTと同様、翻訳の途中状態を複数保持しておく
  - 途中状態のスコアを定義し、スコア上位を残す
  - スコアの計算例
    - 単語の生成確率の積を出力単語数で正規化
    - 過去のattentionの状態をスコアに反映 [Wu et al., 2016]
- SMTとの違い = いつ終わるかわからない
  - <EOS>が出るまでサーチが続く
- 並列計算がしにくく、GPUとの相性が良くない
- softmaxが必要になるため、計算が重たい
- ビームサーチの有無で精度が大きく異なる

# アンサンブル

- 複数のNMTを平行に実行し、単語を一つ出力する際に各NMTからの予測を統合して決定
  - NMTは同じモデルでも、全く異なるモデルでもよい
  - 1つのモデルの訓練途中の複数のパラメータを使ってもよい (loss最小、BLEU最大、最終状態など)が、独立に訓練した複数のNMTを使う方が若干精度が良い

入力: what is the next word?    出力: 次 の 単語 ...

(は, が, を, に, ...)

NMT1 = (0.3, 0.1, 0.2, 0.1, ...)

NMT2 = (0.2, 0.1, 0.6, 0.1, ...)

NMT3 = (0.4, 0.2, 0.1, 0.2, ...)


NMT4 = (0.2, 0.2, 0.3, 0.1, ...)

相加平均  $\frac{1}{M} \sum_{m=1}^M p_m$   
(0.28, 0.15, **0.30**, 0.13, ...)

相乗平均  $\left( \prod_{m=1}^M p_m \right)^{1/M}$   
(**0.26**, 0.14, 0.24, 0.12, ...)

# NMTの特徴

- フレーズテーブルは存在しない
  - 単語アライメント不要、同じモデルで訓練もテストも行う
- SMTのように入力文を「置き換える」ことで翻訳するのではなく、入力文も見ながら、言語モデルのように翻訳文を作り出す
  - <EOS>が(どこかで)出力されたら完了
  - 入力文を過不足なくカバーして翻訳することができない
- 入口(入力文)と出口(翻訳文)以外は全て数値計算(行列の積など)だけで動いている(end-to-end)
- embeddingのおかげで柔軟な翻訳が可能



大変恐れ入りますが、富良野駅ではICカードが  
ご利用になれません。

Thank you very much can not use an IC card  
by furano station very much.

**JR北海道 富良野駅**

# Please

You can not a IC card (Kitaca  
Suica PASMO ICOCA) by furano  
station.

Also IC card charge also  
unavailable.

Very I'm sorry but tickets  
counter in cash and credit card  
is available in a ticket to please.

Or cash only available ticket  
purchase please.

今RTしたやつが、最近のGoogle翻訳でどうなるか見てみたら、Googleの文間を読み取る優しさ能力がスゴイ。

逆に、Google翻訳で正しそうな日本語になったからと言って、元の英文が正しいと信じてはいけないということだと再認識した。

英語 ▾	日本語 ▾
<p>You can not a IC card by Furano station.</p> <p>Also IC card chage also unavailable.</p> <p>Very I'm sorry but tickets counter in cash and credit card is available in a ticket to please.</p> <p>Or cash only available ticket purchase please.</p>	<p>富良野駅ではICカードが使えません。</p> <p>また、ICカードのチャージも利用できません。</p> <p>非常に申し訳ありませんが、チケットは現金でカウンターで、クレジットカードはチケットでご利用いただけます。</p> <p>またはご利用可能なチケットのみご購入ください。</p>

# NMTは本質的には言語モデルと同じ

- エンコードされた入力 $x$ と過去の出力 $y_1 \dots y_{t-1}$ から次の出力単語 $y_t$ を予測

$$p(y_t | y_1, \dots, y_{t-1}, x)$$

- RNNなので $t = 0$ から $K(<\text{EOS}>\text{出力})$ までかけると

$$\prod_{t=1}^K p(y_t | y_1, \dots, y_{t-1}, x) = p(y | x)$$

SMTで求めたい  
ものと同じ！

	言語モデル	NMT
入力( $x$ )	考慮しない	考慮する
過去の出力	数単語前まで考慮	全て考慮
単語の表現	離散的 (単語そのものを利用)	連続的 (実数値ベクトル)

# NMTの短所

- BLEUに対して最適化されていない
  - 通常のトレーニングは1単語出力するごとに、正解の単語と比較(cross-entropy)
  - BLEUなど任意の評価指標を損失関数として使う方法(minimum risk training)もある [Shen et al., 2016]
    - BLEUは向上するが人手評価は変わらない？ [Wu et al., 2016]
- embeddingのせいで全然違う訳が出ることがある
  - I come from Tunisia → ノルウェーの出身です [Arthur et al., 2016]
- attentionの結果はそこまで信用できない



# Attention ≠ Alignment

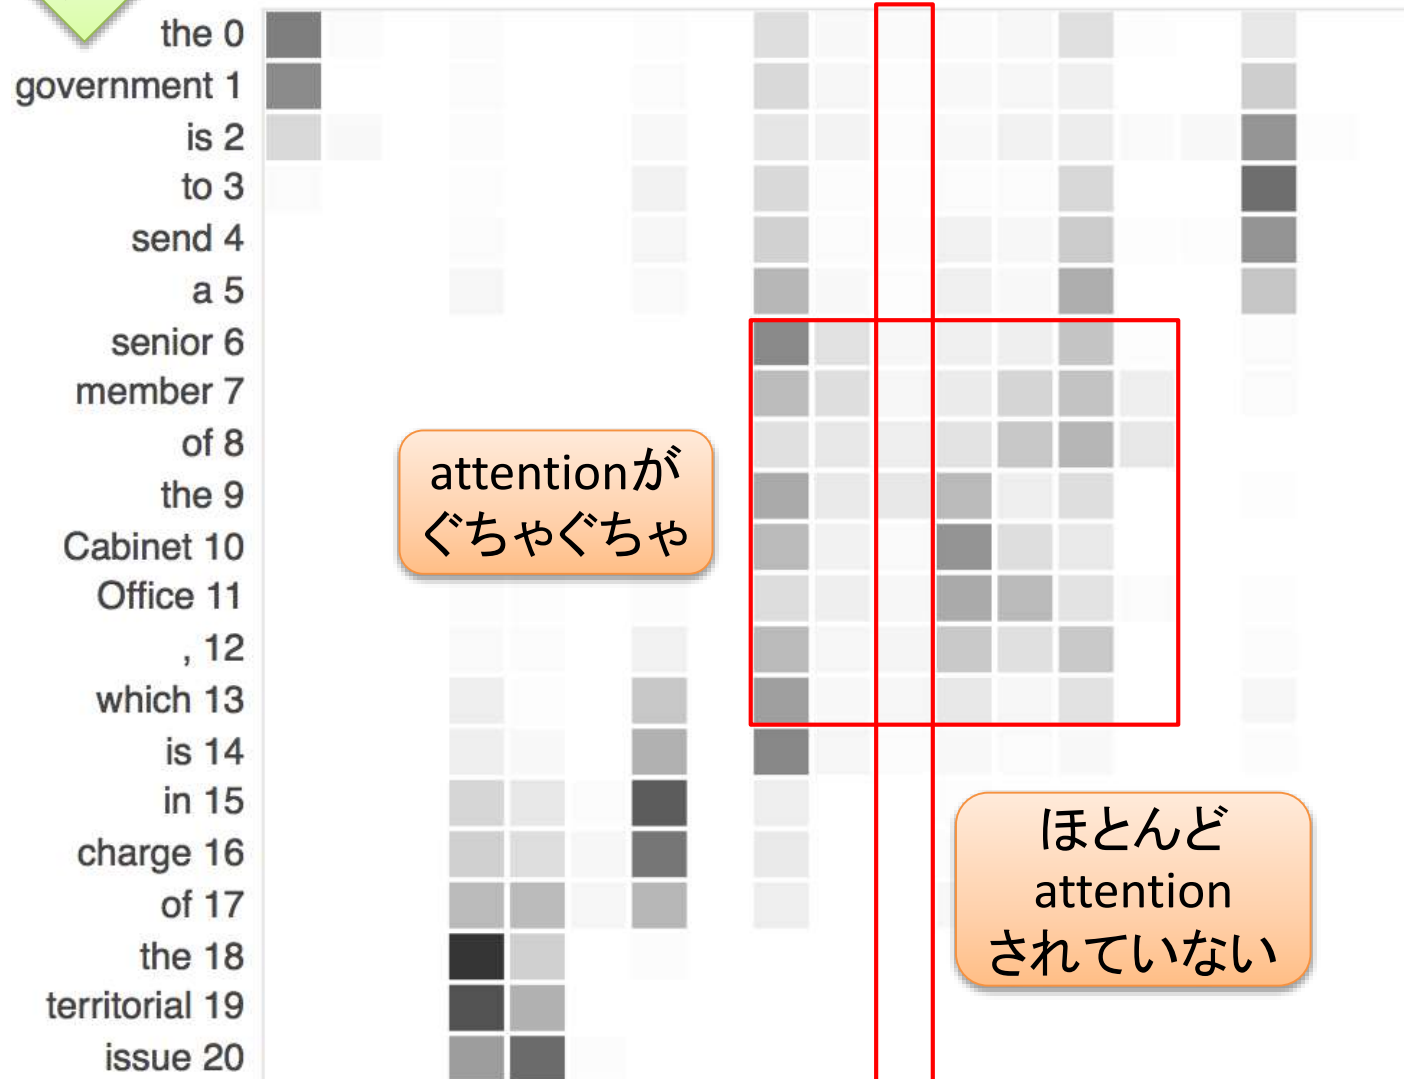
低頻度語は  
特別処理

務台俊介

10 #S\_UNK#

出力  
入力

0 政府 1 は 2、 3 領土 4 問題 5 を 6 担当 7 する 8 務 9 台 10 #S\_UNK# 11 内閣 12 府 13 政務 14 官 15 を 16 派遣 17 する 18、



- 横方向に足すと1
- 縦方向は足しても1にはならない  
→ 全ての入力がカバーされていない
- Alignment Error Rate  
GIZA = 30ぐらい  
Attention = 50ぐらい  
[Liu et al., 2016a]
- GNMTにおいて  
単語対応が  
表示されない要因



# 目次

- NMTの基礎
  - SMTとNMTとの比較
  - Encoder-decoderモデル
  - Attention-based NMT
  - NMTの特徴と短所
- NMTの課題
  - 扱える語彙数が少ない
  - 訳抜けと重複
  - 何を学習しているのかわからない
- NMTのその他の話題
  - 多言語翻訳
  - Low/Zero-resource翻訳
  - モデルの軽量化
  - 特殊タグの埋め込み
  - RNN以外のNMTモデル
- まとめ

# NMTの課題の整理

- 扱える語彙数が少ない
  - [Luong et al., 2015b], [Jean et al., 2015]
  - [Costa-jussà and Fonollosa, 2016], [Chung et al., 2016], [Luong and Manning, 2016], [Sennrich et al., 2016b]
- 訳抜けと重複
  - [Tu et al., 2016a], [Tu et al., 2016b]
- 何を学習しているのかわからない
  - [Shi et al., 2016a], [Shi et al., 2016b]

# NMTの課題の整理

- 扱える語彙数が少ない
  - [Luong et al., 2015b], [Jean et al., 2015]
  - [Costa-jussà and Fonollosa, 2016], [Chung et al., 2016], [Luong and Manning, 2016], [Sennrich et al., 2016b]
- 訳抜けと重複
  - [Tu et al., 2016a], [Tu et al., 2016b]
- 何を学習しているのかわからない
  - [Shi et al., 2016a], [Shi et al., 2016b]

# NMTにおける語彙サイズの問題

- Softmaxの計算が重たいため、語彙サイズを制限
  - 頻度順で上位3万から5万程度、多くても10万
- 語彙範囲外の単語は特別な記号 <UNK> に置換
- 出力中の <UNK> に対応する単語を辞書等で翻訳
  - 単語アライメント結果を使って対訳文を修正

[Luong et al., 2015b]

En: The unk portico in unk ...

Fr: Le unkpos<sub>1</sub> unkpos<sub>-1</sub> de unkpos<sub>0</sub>

添え字は対応する  
入力単語の相対位置

- <UNK>を出力する際に最も強くattentionした入力単語で置き換え [Jean et al., 2015]

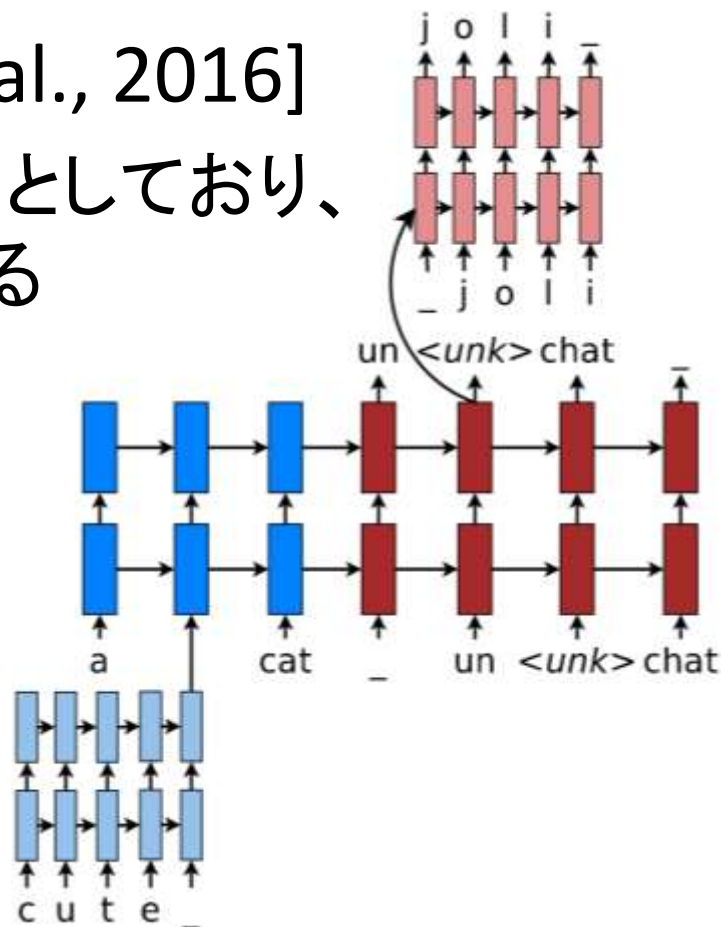
これらの方法は copy model/mechanism と呼ばれる

# 単語ではなく文字を使う

- 入力のみ文字 [Costa-jussà and Fonollosa, 2016]
- 出力のみ文字 [Chung et al., 2016]
- 入力も出力も文字のみ [Lee et al., 2016]
  - 上記3つは単語間の空白も1文字としており、間接的に単語の情報を使っている

- 単語と文字のハイブリッド

- 単語単位のNMTがベース
- 入力の<UNK>は文字単位のエンコーダーが表現を作る
- 出力の<UNK>は文字単位で翻訳



# 単語と文字の中間的な単位(sub-word)

[Sennrich et al., 2016b]

- Byte Pair Encoding (BPE) <https://github.com/rsennrich/subword-nmt>
  - データ圧縮方法として提案されたアルゴリズム (1994)
  - 全ての文字を語彙に登録するところからスタート
  - データの中で最も頻度の高い2文字の連続を新たな語彙として登録
  - 設定された最大語彙サイズまで登録を繰り返す
- Wordpiece Model (WPM)
  - Googleが使っているsub-word unit (BPEと同じ)
- SentencePiece <https://github.com/google/sentencepiece>
  - Googleの工藤さんが作ったもの
  - 事前単語分割不要で、文から直接sub-wordを学習

# Byte Pair Encodingのアルゴリズム

[Sennrich et al., 2016b]

## コーパス

頻度	単語	単語	単語	単語	単語
5	low	low	<u>low</u>	<u>low</u>	low
2	lower	lower	<u>lower</u>	<u>lower</u>	lower
6	new <u>est</u>	new <u>est</u>	new est	new est	new est
3	wid <u>est</u>	wid <u>est</u>	wid est	wid est	wid est

語彙 (サイズ = 15)

初期語彙 = 文字 (11個)

l, o, w, e, r, n, w, s, t, i, d

es (頻度 = 9)

lo (頻度 = 7)

est (頻度 = 9)

low (頻度 = 7)

# Sub-wordの影響 (GNMTの例)

逗子市小坪5-1の小坪海岸トンネル鎌倉側で、9月24日0 時頃、大きな崖崩れが発生しました。



A large cliff collapse occurred around 0 o'clock on September 24th at the Kobosa coast tunnel Kamakura side of Zushi-shi Kobosa 5-1.

小坪 → Koonsubo

小坪海岸 → Kobosu coast

逗子市小坪 → Zushi-shi Kosubo

逗子市の小坪 → Zushi in Zushi City



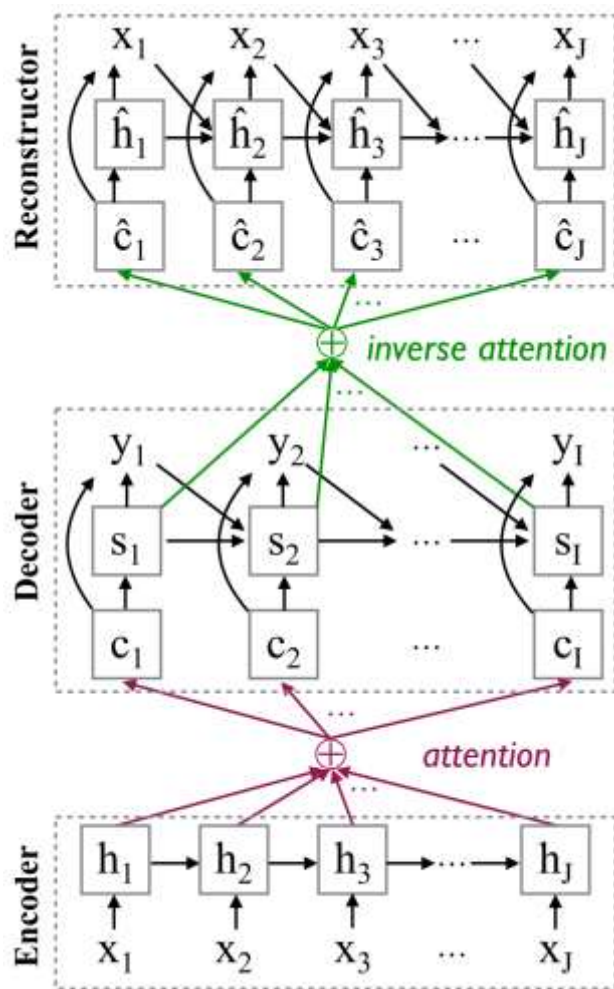
# NMTの課題の整理

- 扱える語彙数が少ない
  - [Luong et al., 2015b], [Jean et al., 2015]
  - [Costa-jussà and Fonollosa, 2016], [Chung et al., 2016], [Luong and Manning, 2016], [Sennrich et al., 2016b]
- 訳抜けと重複
  - [Tu et al., 2016a], [Tu et al., 2016b]
- 何を学習しているのかわからない
  - [Shi et al., 2016a], [Shi et al., 2016b]

# Neural Machine Translation with Reconstruction

[Tu et al., 2016a]

- 通常のNMTで翻訳し、さらにそれを原文に翻訳し直す(Reconstructor)モジュールを追加



モデル	訳抜け	重複 (過剰訳)
ベースライン	18.2%	3.9%
+ reconstruction	16.2%	2.4%

# Modeling Coverage for Neural Machine Translation

[Tu et al., 2016b]

- 入力文のどの単語が翻訳されたかを追跡するカバレッジベクトルを追加
- カバレッジベクトルをattentionの計算に利用
- 根本解決からは程遠い

System	SAER	AER
GroundHog	67.00	54.67
+ Ling. cov. w/o fertility	66.75	53.55
+ Ling. cov. w/ fertility	64.85	52.13
+ NN cov. w/o gating ( $d = 1$ )	67.10	54.46
+ NN cov. w/ gating ( $d = 1$ )	66.30	53.51
+ NN cov. w/ gating ( $d = 10$ )	<b>64.25</b>	<b>50.50</b>

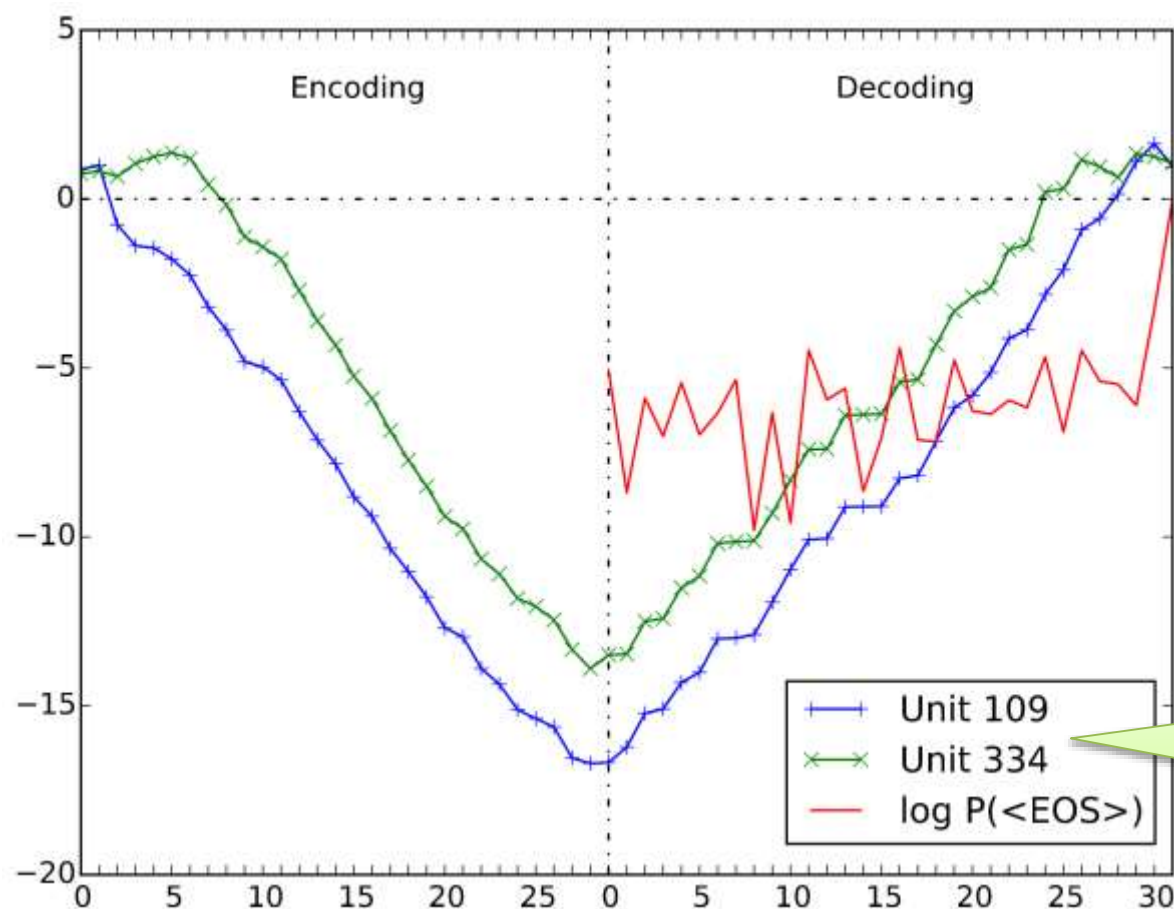
# NMTの課題の整理

- 扱える語彙数が少ない
  - [Luong et al., 2015b], [Jean et al., 2015]
  - [Costa-jussà and Fonollosa, 2016], [Chung et al., 2016], [Luong and Manning, 2016], [Sennrich et al., 2016b]
- 訳抜けと重複
  - [Tu et al., 2016a], [Tu et al., 2016b]
- 何を学習しているのかわからない
  - [Shi et al., 2016a], [Shi et al., 2016b]

# Why Neural Translations are the Right Length

[Shi et al., 2016a]

- attentionなしの翻訳モデルの隠れ層を分析
  - 出力の長さをコントロールしているunitが複数存在
  - $\langle \text{EOS} \rangle$ の確率は最後に急に高くなる



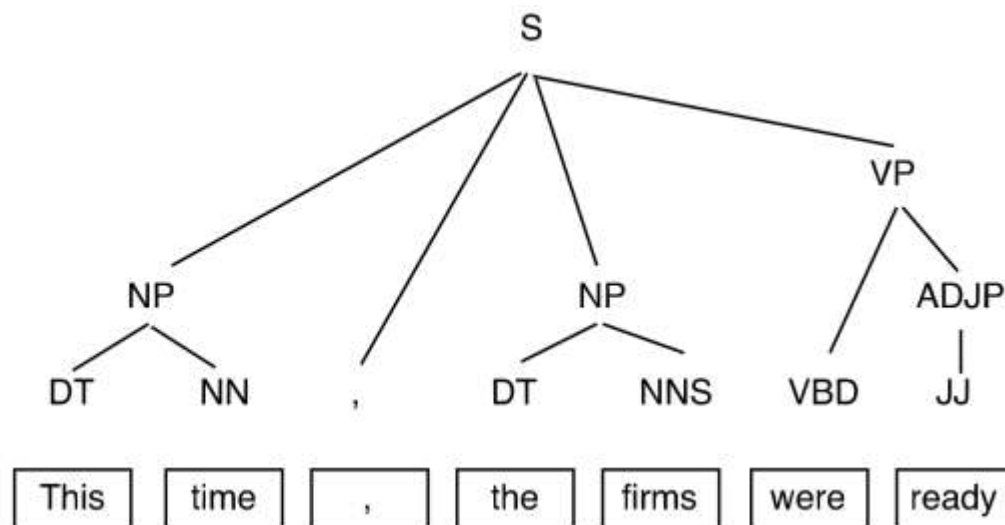
$\langle \text{EOS} \rangle$ の確率は  
最後だけ高い

実験ではこの2つの  
Unitが最も長さに関与

# Does String-Based Neural MT Learn Source Syntax?

[Shi et al., 2016b]

- attentionなしの翻訳モデルの入出力を様々に変え、隠れ層を使ったロジスティック回帰で以下を予測

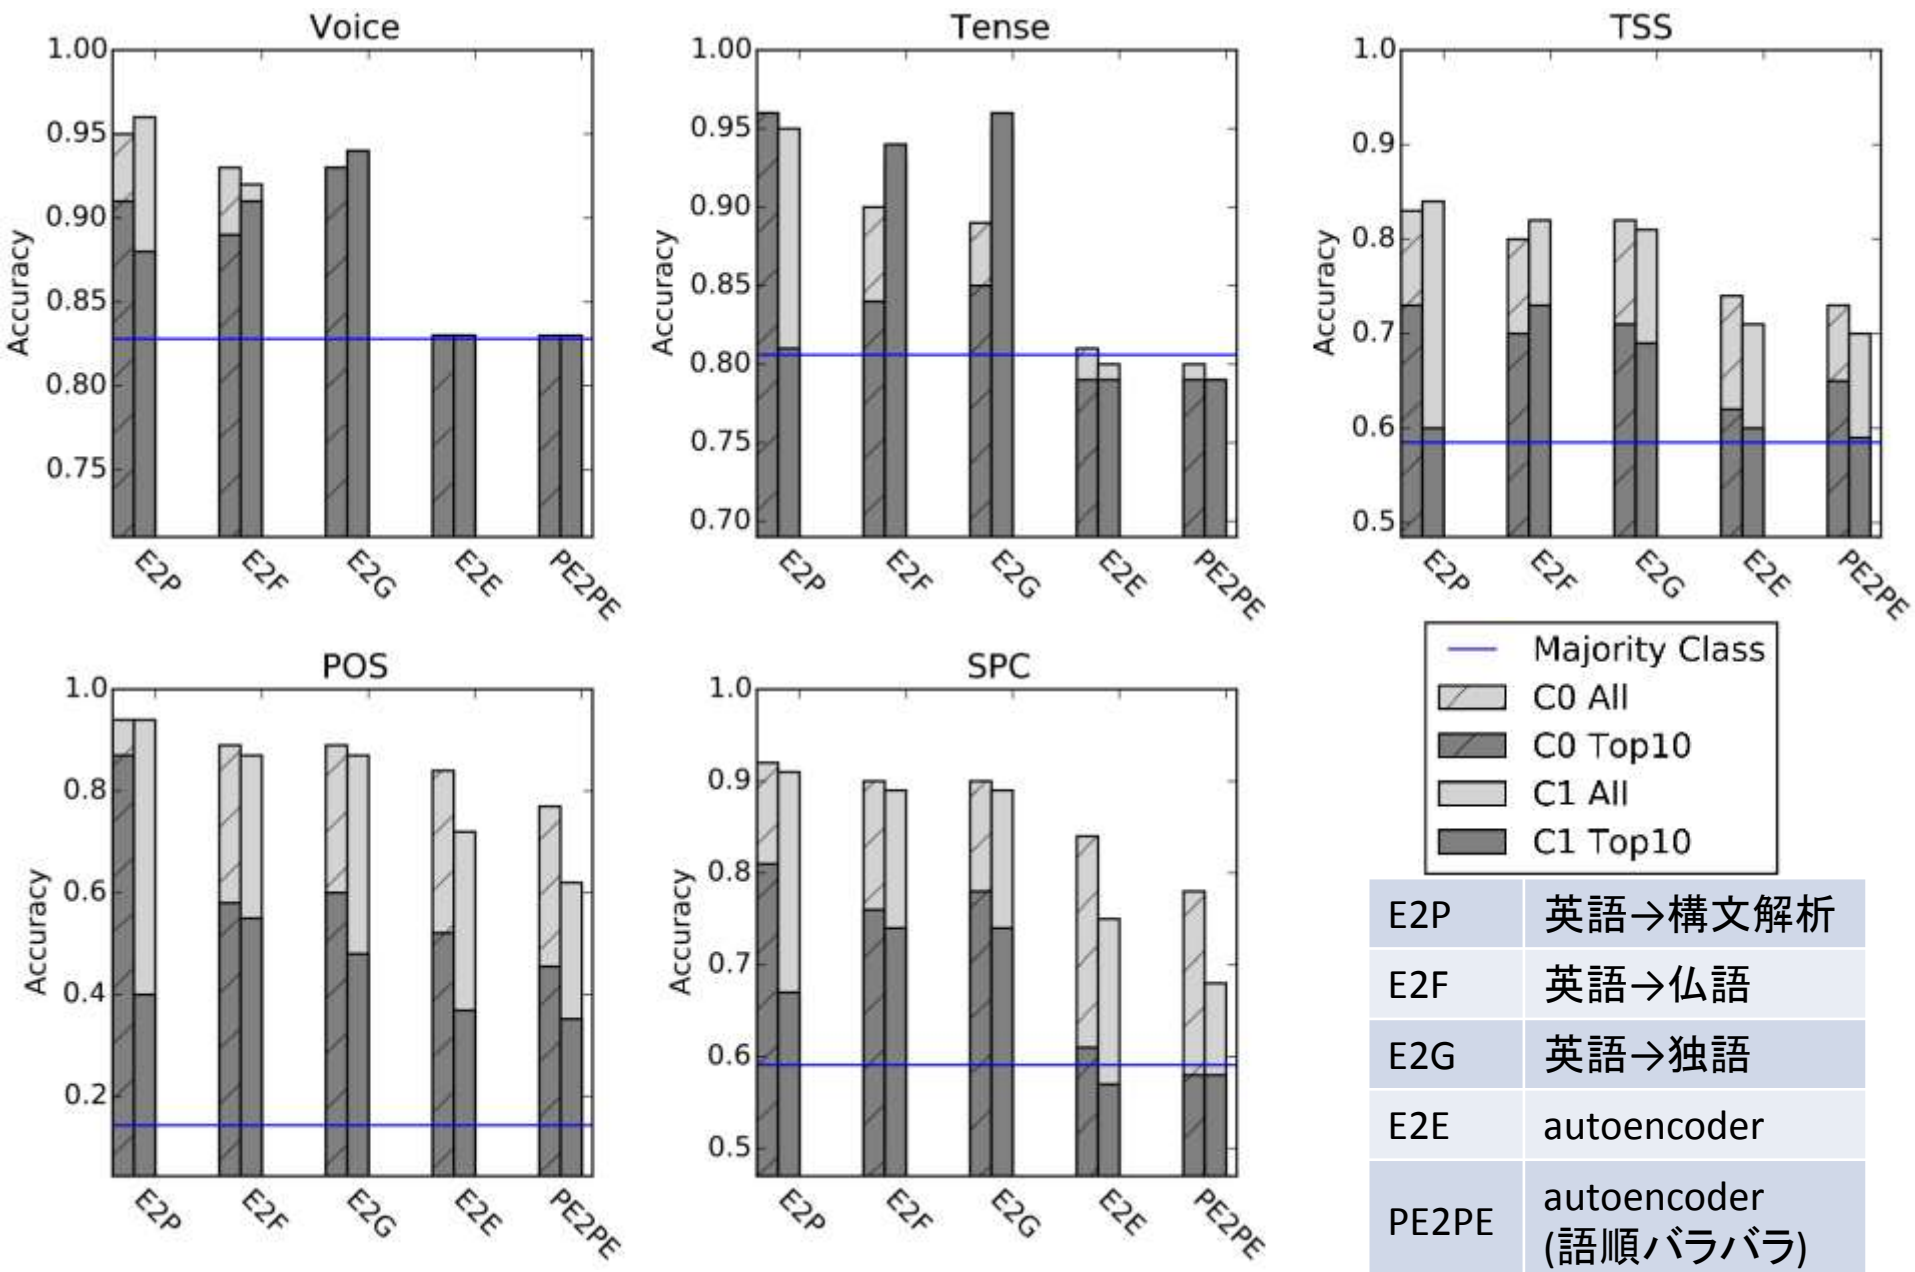


	This	time	,	the	firms	were	ready
POS	DT	NN	,	DT	NNS	VBD	JJ
Smallest Phrase Constituent	NP	NP	-	NP	NP	VP	ADJP
Top-level Syntactic Sequence	(NP, NP, VP)						
Voice	Active						
Tense	Past						

各単語を読み込んだ  
時点での隠れ層の  
状態を利用

隠れ層の  
最後の状態を利用


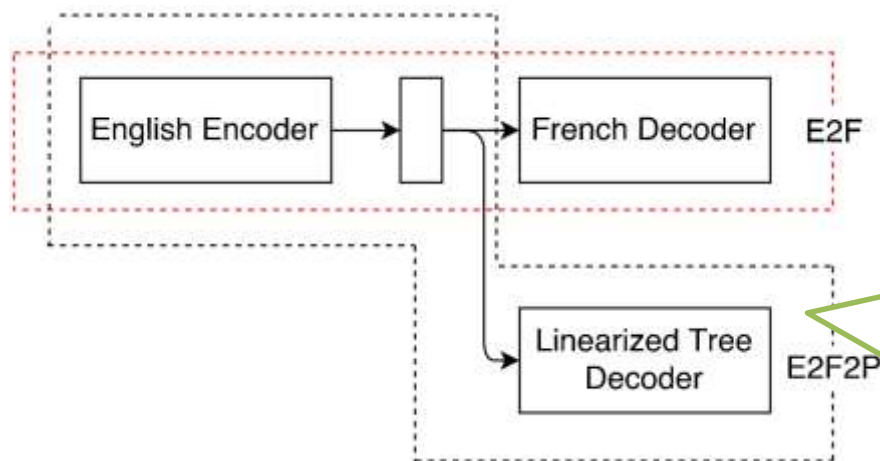
# Does String-Based Neural MT Learn Source Syntax?



E2P	英語→構文解析
E2F	英語→仏語
E2G	英語→独語
E2E	autoencoder
PE2PE	autoencoder (語順バラバラ)

# Does String-Based Neural MT Learn Source Syntax?

- まず普通にencoder-decoderを学習し、encoderのパラメータを固定してdecoderのparserを学習



(S (NP NNP )NP (VP VBZ (NP DT NN )NP )VP . )S

[Vinyals et al., 2015]

Model	Labeled F1	POS Tagging Accuracy
PE2PE2P	58.67	54.32
E2E2P	70.91	68.03
E2G2P	85.36	85.30
E2F2P	86.62	87.09
E2P	93.76	96.00

autoencoderで学習された情報では  
parseできない → 構文情報は  
学習されていない

NMTで学習された情報ならある程度  
parseできる → なんらかの構文情報が  
学習されている



# 目次

- NMTの基礎
  - SMTとNMTとの比較
  - Encoder-decoderモデル
  - Attention-based NMT
  - NMTの特徴と短所
- NMTの課題
  - 扱える語彙数が少ない
  - 訳抜けと重複
  - 何を学習しているのかわからない
- NMTのその他の話題
  - 多言語翻訳
  - Low/Zero-resource翻訳
  - モデルの軽量化
  - 特殊タグの埋め込み
  - RNN以外のNMTモデル
- まとめ

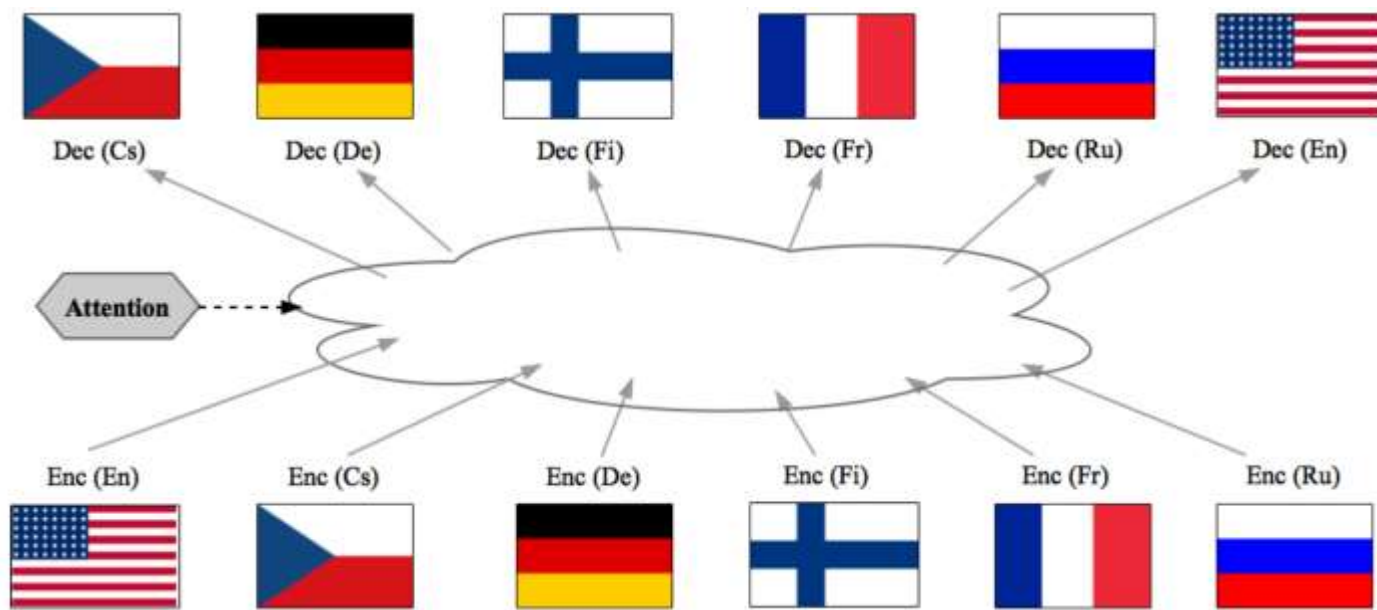
# 多言語化が容易

- SMTは基本的に記号の置き換えであるため、多言語対訳コーパスを同時に利用することは困難
- NMTは基本的に数値計算なので、言語に依らず同じ意味を表すものを同じような値に変換できれば翻訳可能
  - 昔からある中間言語のようなもの
- 直接の対訳コーパスがない言語対であっても翻訳可能（ゼロショット翻訳）
  - SMTでは英語などをピボット言語として用い、二段階に翻訳するなどする必要があった

# Multi-Way, Multilingual Neural Machine Translation with a Shared Attention Mechanism

[Firat et al., 2016a]

- 言語ごとにencoderとdecoderを用意  
attention機構のみ全言語共通



- 直接の対訳コーパスが少ない時には効果あり

# Google's Multilingual Neural Machine Translation System: Enabling Zero-Shot Translation

[Johnson et al., 2016]

- 入力文に <2es> (スペイン語への翻訳)のようなタグをつけ、全ての言語対の対訳コーパスを同時に使うだけでゼロショット翻訳もできるようになる
- “<2en> 私は東京大学학생입니다” みたいなことも
- ちなみに語彙サイズは全言語共通で32k (WPM)


# モデルの軽量化

- SMTのモデルは巨大だった・・・
  - フレーズテーブル、言語モデルなどなど
  - 数十GB、数百GB、数TB
- NMTは実数の行列を保存しておけばよい
  - ネットワークの大きさによるが、せいぜい数GB
- NMTのモデルをさらに軽量化する方法もある
  - 量子化 [Wu et al., 2016]
  - 枝刈り (pruning) [See et al., 2016]
  - 蒸留 (distillation) [Kim and Rush, 2016]

# Compression of Neural Machine Translation Models via Pruning

[See et al., 2016]

- パラメータの絶対値が小さいものから順に枝刈り
  - パラメータと同じshapeのmask行列を使って値を0に
- 枝刈りすると精度は下がるが、再訓練すれば元の精度まで戻せる
- 初めから枝刈りした状態で訓練してもだいたい同じ精度に



# Sequence-Level Knowledge Distillation

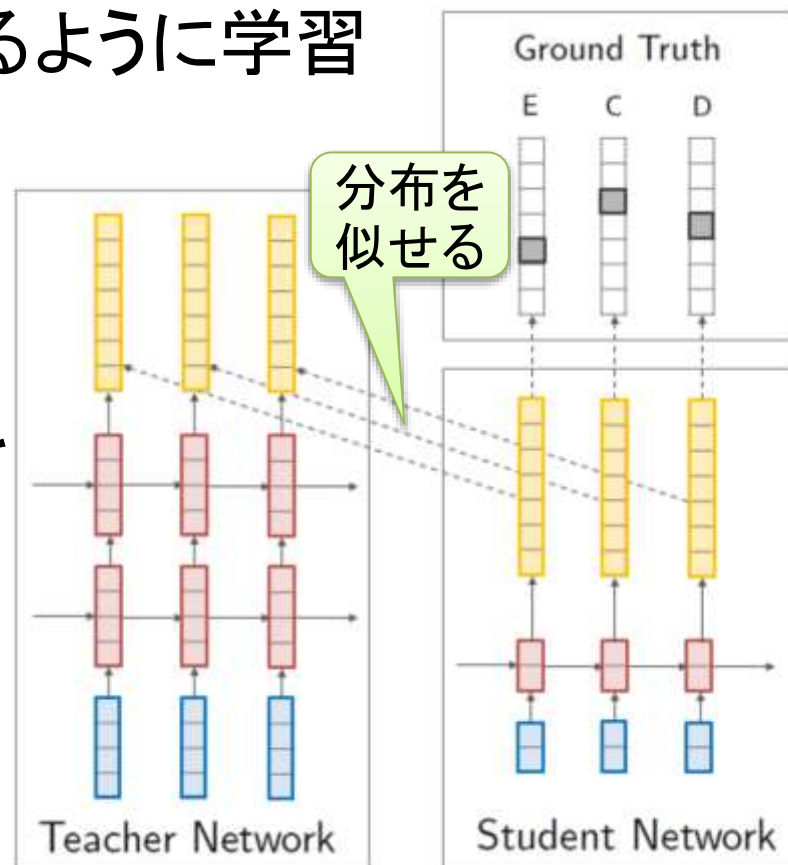
[Kim and Rush, 2016]

- 知識蒸留

- 大きなネットワークからなる教師モデルを訓練しておきより小さなネットワークの生徒モデルを訓練する際に教師モデルの予測分布に似るように学習

- 1つだけの正解から学習するよりも、教師モデルの予測分布を使えるため、効率が良い

- 1単語出力するごとに分布を似せるだけでなく、出力文全体としての分布を似せる方法(sequence-level)も提案



# Sequence-Level Knowledge Distillation

[Kim and Rush, 2016]

- 教師モデルより1/5から1/6の生徒モデルでも教師モデルと遜色ない精度を達成
- なぜかビームサーチをしなくても精度が出るように
- Galaxy 6上でNMTが動く！ (iPhone 8/Xなら・・・)

1秒間に翻訳できる単語数

Model Size	GPU	CPU	Android
<i>Beam = 1 (Greedy)</i>			
4 × 1000	425.5	15.0	—
2 × 500	1051.3	63.6	8.8
2 × 300	1267.8	104.3	15.8
<i>Beam = 5</i>			
4 × 1000	101.9	7.9	—
2 × 500	181.9	22.1	1.9
2 × 300	189.1	38.4	3.4

さらに枝刈りも実施

Model	Prune %	Params	BLEU	Ratio
4 × 1000	0%	221 m	19.5	1×
2 × 500	0%	84 m	19.3	3×
2 × 500	50%	42 m	19.3	5×
2 × 500	80%	17 m	19.1	13×
2 × 500	85%	13 m	18.8	18×
2 × 500	90%	8 m	18.5	26×

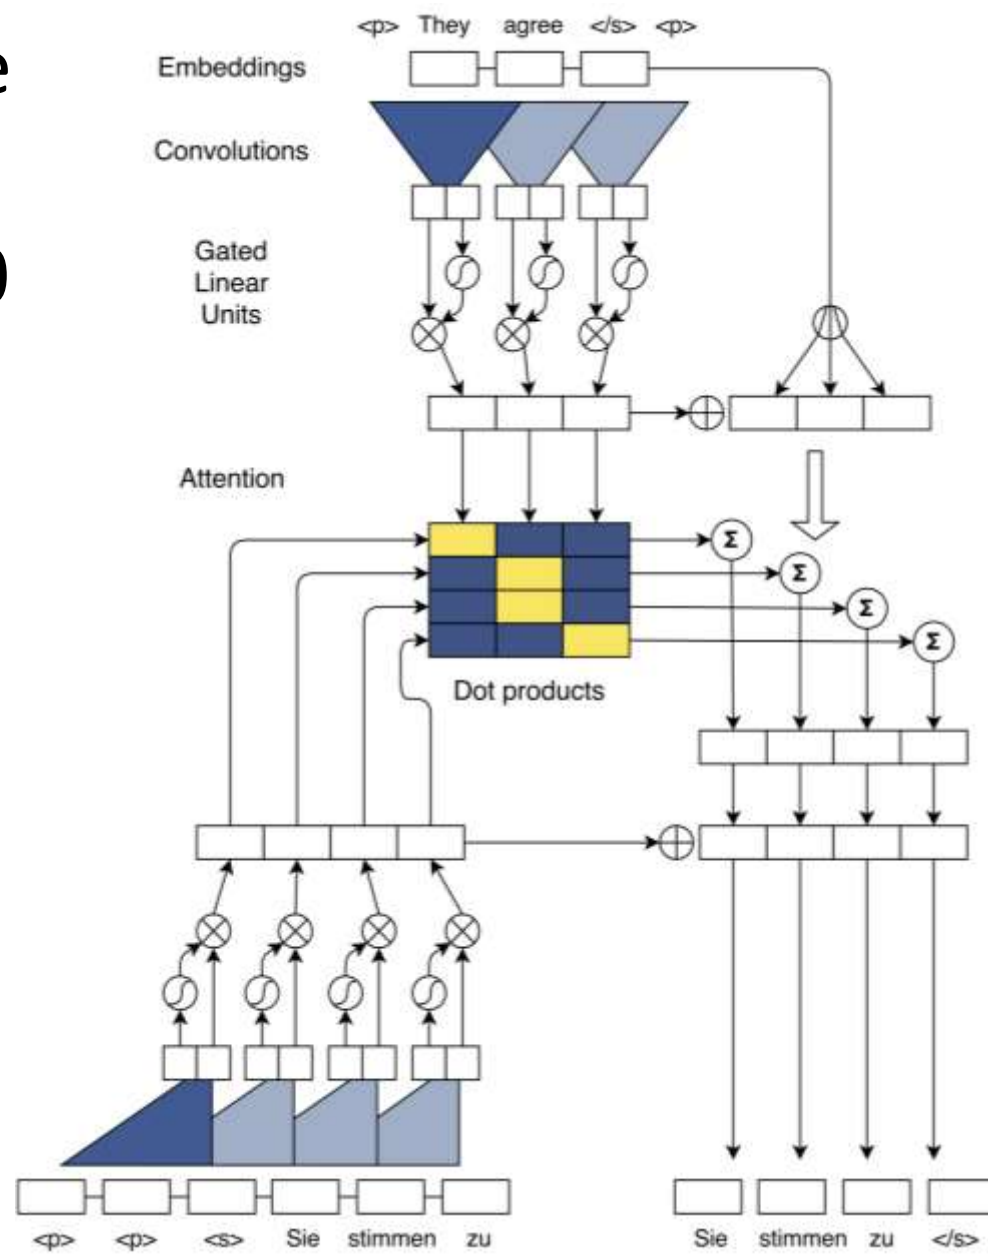


# その他のNMTモデル

- Convolutional Sequence to Sequence Learning
  - <https://arxiv.org/abs/1705.03122>
  - RNNではなくCNNを使うことで高速化
- Attention Is All You Need
  - <https://arxiv.org/abs/1706.03762>
  - RNNもCNNもいらない！ Feed-forwardのみ
  - Self-attentionにより代名詞の実体も考慮できる
- Unsupervised Neural Machine Translation
  - <https://arxiv.org/abs/1710.11041>
  - 対訳コーパスいらない！

# その他のNMTモデル (1/3)

- Convolutional Sequence to Sequence Learning
  - <https://arxiv.org/abs/1705.03122>
  - RNNではなくCNNを使うことで高速化




# その他のNMTモデル (2/3)

- Attention Is All You Need
  - <https://arxiv.org/abs/1706.03762>
  - RNNもCNNもいらない！ Feed-forwardのみのTransformerを提案
  - Self-attentionにより代名詞の実体も考慮できる


*The animal didn't cross the street because it was too tired.  
L'animal n'a pas traversé la rue parce qu'il était trop fatigué.*

*The animal didn't cross the street because it was too wide.  
L'animal n'a pas traversé la rue parce qu'elle était trop large.*

# その他のNMTモデル (2/3)




# その他のNMTモデル (2/3)




# Attention Is All You Need (AIAYN) 強し

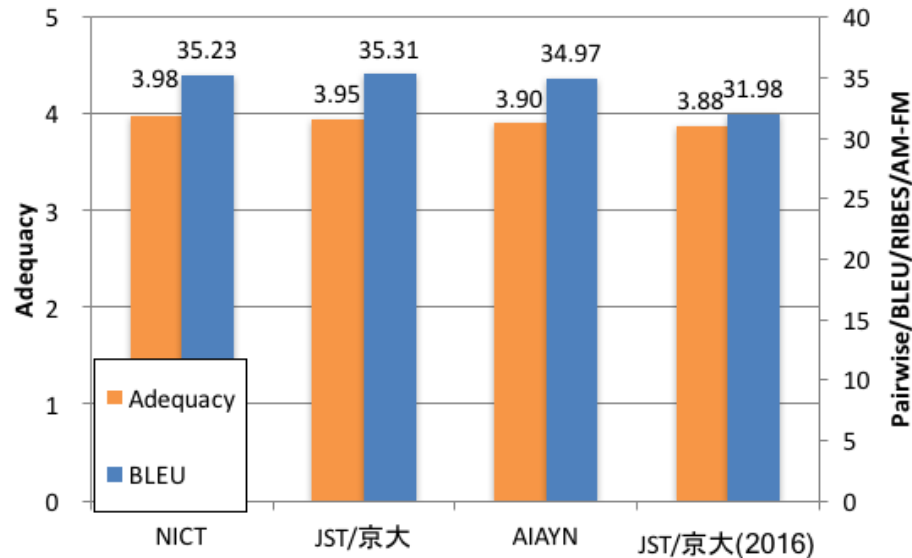
日→英翻訳上位チーム評価結果




英→日翻訳上位チーム評価結果



日→中翻訳上位チーム評価結果



中→日翻訳上位チーム評価結果



# その他のNMTモデル (3/3)

- Unsupervised Neural Machine Translation
  - <https://arxiv.org/abs/1710.11041>
  - 対訳コーパスいらない！(単言語コーパスだけで翻訳)
  - Unsupervised cross-lingual embeddingを使い、NMTの学習中は更新しない
  - Encoderは両言語共通のものを使う(decoderは独立)
  - 語順を入れ替えた文を入力として元の語順を復元する *denoising* と、通常の入力を相手言語に翻訳し、さらに元の言語に逆翻訳する *backtranslation* をバッチごとに入れ替えて訓練

# その他のNMTモデル (3/3)

- Unsupervised Machine Translation Using Monolingual Corpora Only
  - <https://arxiv.org/abs/1711.00043>
  - 前のスライドの論文の翌日に投稿された！
  - denoisingとbacktranslationを使うのは同じ、embeddingとencoderは各言語独立
  - 違いはencoderの出力を言語非依存の空間にmapするために敵対性学習を行う
    - どちらの言語でも同じ内容の文は同じようにencodeされる
    - 敵対ネットワークはencodeされたものがどちらの言語のものかを当てる



# 目次

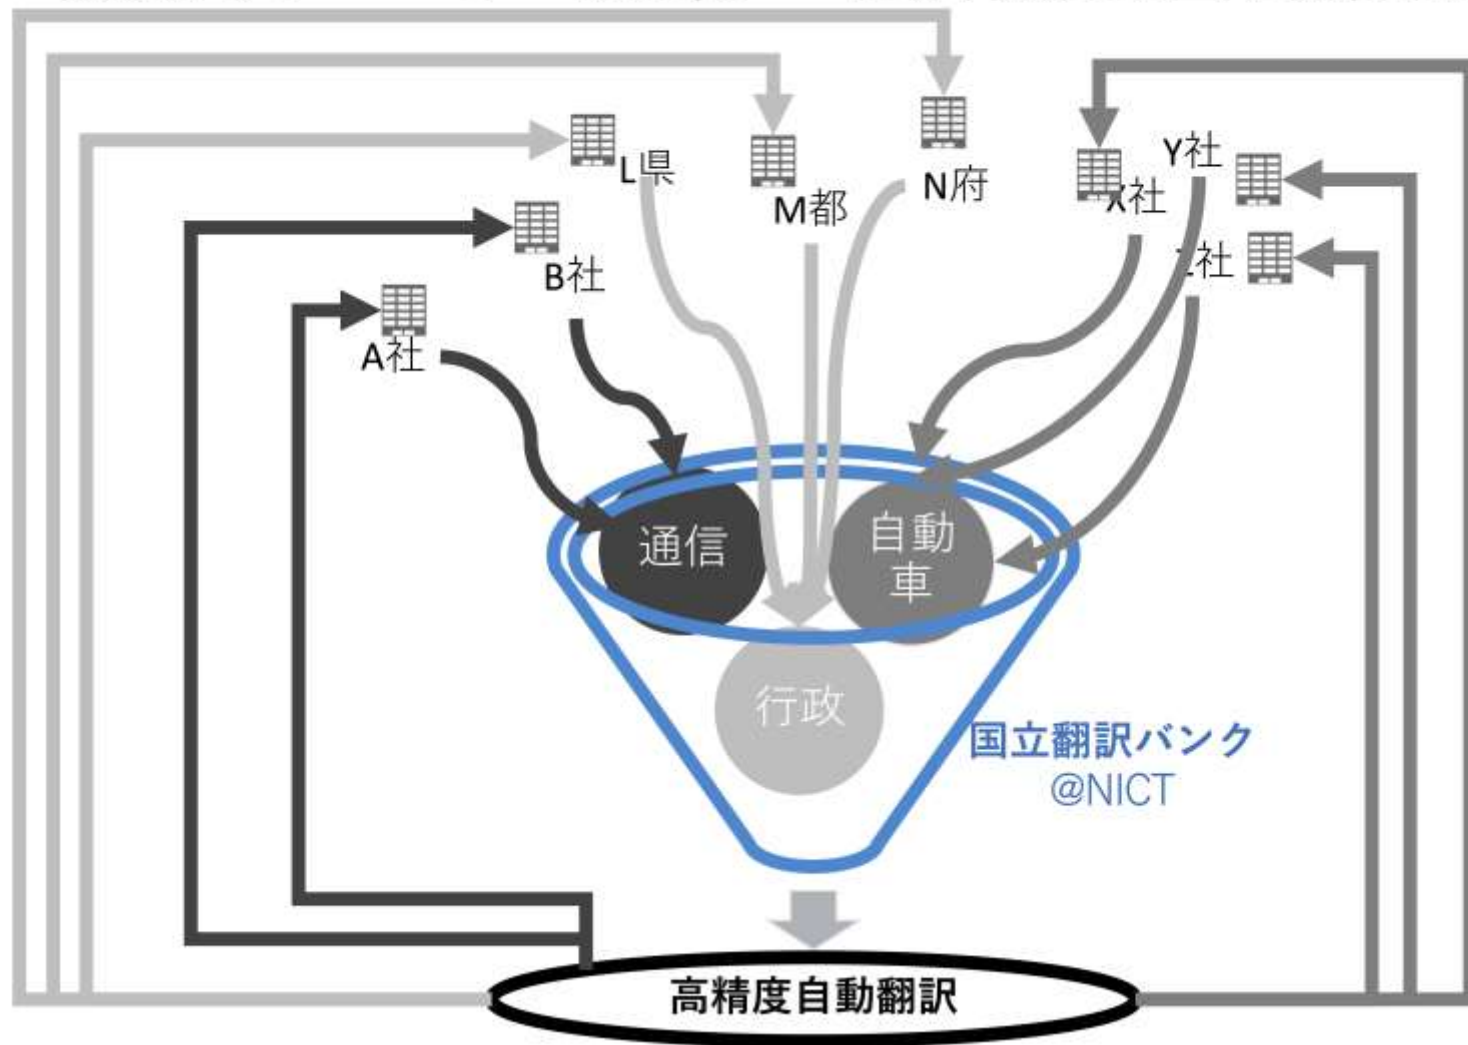
- NMTの基礎
  - SMTとNMTとの比較
  - Encoder-decoderモデル
  - Attention-based NMT
  - NMTの特徴と短所
- NMTの課題
  - 扱える語彙数が少ない
  - 訳抜けと重複
  - 何を学習しているのかわからない
- NMTのその他の話題
  - 多言語翻訳
  - Low/Zero-resource翻訳
  - モデルの軽量化
  - 特殊タグの埋め込み
  - RNN以外のNMTモデル
- まとめ

# 翻訳エンジンには価値がない？

- すでに多くのNMTエンジンがオープンソース
  - SYSTRANも使っているエンジン: OpenNMT
  - 最先端の研究成果も利用可能
- 他の大手企業も技術を論文で公開
  - Baidu [He, 2015], Google [Wu et al., 2016]
- SMTのように開発に職人技が必要なこともない
  - 既存のモデルなら学生が1週間かければ作れる
  - 逆にいうと、MT研究への参入障壁が大幅に低下
- じゃあ(企業にとって)何が重要なのか？
  - おそらくデータ、あとエンジンを使いこなせる人

# 日本でのデータ共有の試み

翻訳データ収集 ⇒ 高精度自動翻訳



# 今後の展望

- NMTはここ数年で急激に発展し、SMTの精度を追い越している
- NMTの研究はまだ発展する可能性が高い
- 現状のNMTには解決すべき課題が多く残されており、実用的かと言われると疑問が残る
  - Gisting目的ならば十分
  - SMTが活躍する場もまだ残っていることは確かで、うまく組み合わせられると良い
  - 特に対訳コーパスが少量の場合NMTはSMTよりも弱い
  - NMTの発展次第ではSMTが遺産になる可能性もある

# 関東/関西MT勉強会

- <https://sites.google.com/site/machinetranslationjp/>
- MTに関する話題をざくばらんに扱っています
- 内容は基本的にオフレコです
- 参加自由、研究者ではない方もぜひご参加下さい
- 次回は11/18(土)@NAIST

# ありがとうございました

質問等は以下まで

nakazawa@nlp.ist.i.kyoto-u.ac.jp

zawa13@gmail.com

Twitter: @Tzawa